Raport z laboratorium: Systemy Sztucznej Inteligencji

Grupowanie Danych (K-Średnie)

Jakub Filipiak

11 października 2026

1 Wprowadzenie

Celem ćwiczenia było zapoznanie się z algorytmami grupowania danych (klasteryzacji) ze szczególnym uwzględnieniem algorytmu K-średnich. Badano wpływ wyboru różnych miar odległości na wynik podziału zbioru danych składającego się ze 101 próbek o dwóch atrybutach (wygenerowanych zgodnie z podanym wzorem) na zadane grupy.

2 Zadanie 1: K-Średnie, Miara Euklidesowa (3 grupy)

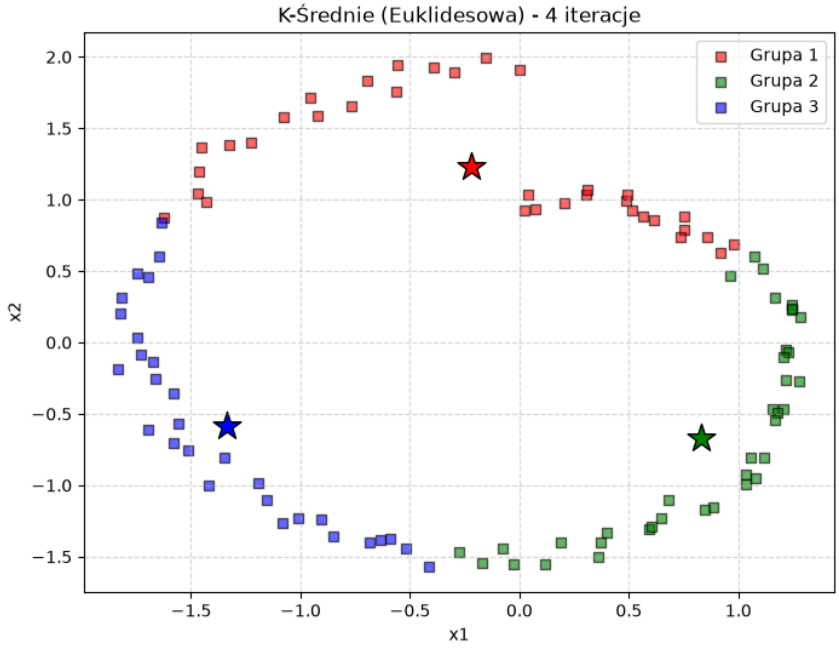
W pierwszym badaniu algorytm K-średnich skonfigurowano na podział na $k = 3$ grupy. Jako miarę podobieństwa zastosowano standardową odległość euklidesową na płaszczyźnie $\mathbb{R}^2$.

2.1 Stan po 4 iteracjach

Poniższa tabela prezentuje położenie środków grup, liczbę przypisanych próbek oraz zakresy wartości atrybutów dla poszczególnych klastrów po wykonaniu 4 pełnych iteracji algorytmu.

Grupa	**Środek** (x_1, x_2)	**L. próbek**	**Min** x_1	**Max** x_1	**Min** x_2	**Max** x_2
Grupa 1	(-0,7330, 1,2568)	32	-1,8021	0,4854	0,2922	2,0595
Grupa 2	(0,9561, -0,2744)	39	0,2623	1,3246	-1,4529	0,8975
Grupa 3	(-1,0290, -0,9657)	30	-1,8085	0,1375	-1,5865	0,2890

Tabela 1: Zestawienie parametrów grup po 4 iteracjach (odległość euklidesowa, k=3).



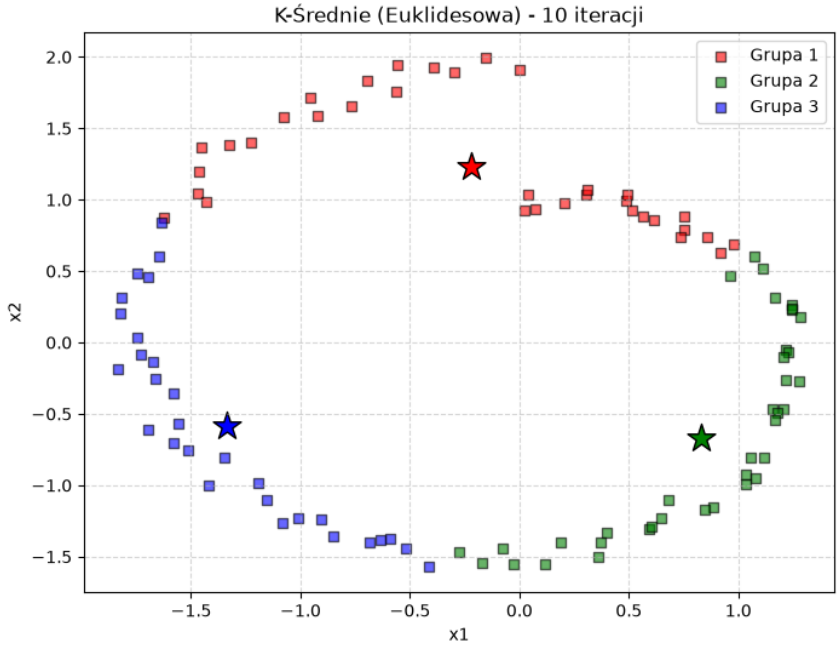
Rysunek 1: Wykres położenia środków i przynależności próbek po 4 iteracjach.

2.2 Stan po 10 iteracjach

Poniższa tabela prezentuje stan po 10 iteracjach. Można zauważyć stabilizację algorytmu i nieznaczne przesunięcia środków względem iteracji czwartej.

Grupa	**Środek** (x_1, x_2)	**L. próbek**	**Min** x_1	**Max** x_1	**Min** x_2	**Max** x_2
Grupa 1	(-0,7656, 1,2275)	33	-1,8085	0,4854	0,2890	2,0595
Grupa 2	(0,9561, -0,2744)	39	0,2623	1,3246	-1,4529	0,8975
Grupa 3	(-1,0021, -1,0090)	29	-1,7634	0,1375	-1,5865	0,1236

Tabela 2: Zestawienie parametrów grup po 10 iteracjach (odległość euklidesowa, k=3).



Rysunek 2: Wykres położenia środków i przynależności próbek po 10 iteracjach.

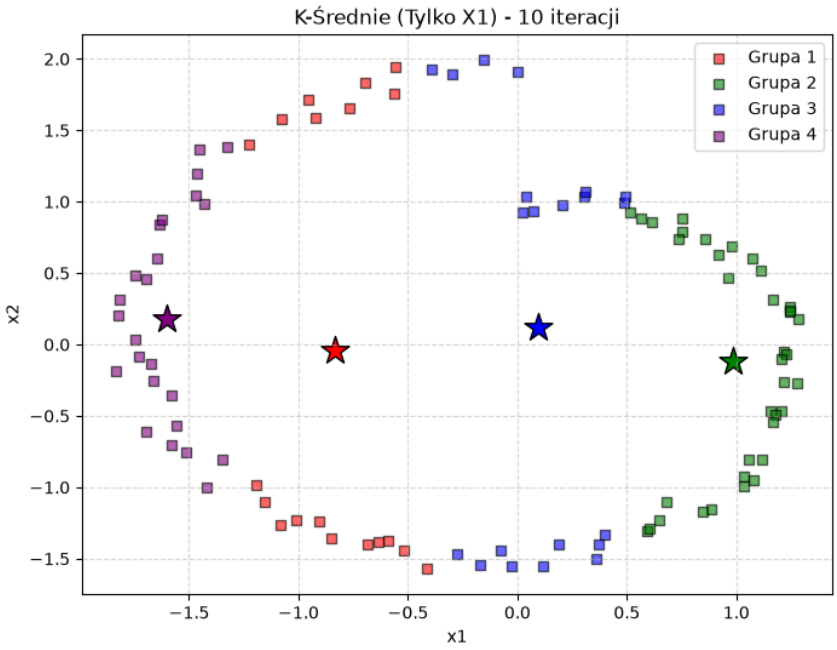
3 Zadanie 2: K-Średnie, Miara bazująca tylko na atrybucie x_1 (4 grupy)

W drugim etapie użyto algorytmu K-średnich na $k = 4$ grupy. Zmodyfikowano miarę odległości – ignorowano parametr x_2, a odległość pomiędzy punktami zdefiniowano jako $|x_{1_A} - x_{1_B}|$. Oznacza to grupowanie próbek wyłącznie na podstawie ich odciętej wzdłuż osi X.

3.1 Stan po 10 iteracjach

Grupa	**Środek** (x_1, x_2)	**L. próbek**	**Min** x_1	**Max** x_1	**Min** x_2	**Max** x_2
Grupa 1	(-1,6208, 0,1817)	24	-1,8085	-1,2978	-1,0513	1,4755
Grupa 2	(1,0071, -0,1821)	36	0,5336	1,3246	-1,4438	0,8975
Grupa 3	(-0,8895, 0,0234)	18	-1,2457	-0,4933	-1,5081	1,9380
Grupa 4	(0,0704, 0,1008)	23	-0,3755	0,4854	-1,5865	2,0595

Tabela 3: Zestawienie parametrów grup po 10 iteracjach (odległość tylko względem x_1, k=4).



Rysunek 3: Wykres położenia środków i przynależności próbek po 10 iteracjach dla odległości opartej na x_1.

4 Wnioski

Algorytm K-średnich wykazuje dużą zbieżność – znaczące różnice w położeniu środków grup i dystrybucji próbek w klastrach obserwowane są w pierwszych iteracjach, a między iteracją 4 a 10 zmiany są stosunkowo niewielkie (dla miary euklidesowej liczba próbek w grupach uległa zmianie zaledwie o 1 element). Niezwykle istotny wpływ na kształt powstających klastrów ma wyznaczona miara odległości. Zastosowanie odległości bazującej wyłącznie na jednym atrybucie (zadanie 2) powoduje "pionowe"cięcia zbioru danych niezależnie od odległości punktów na osi rzędnych.